

Regresión

Logística

Clasificación



1

Clasificación

Email: ¿*Spam* / *Not Spam*?

Transacciones online: *Fraudulentas* ¿*Si* / *No*?

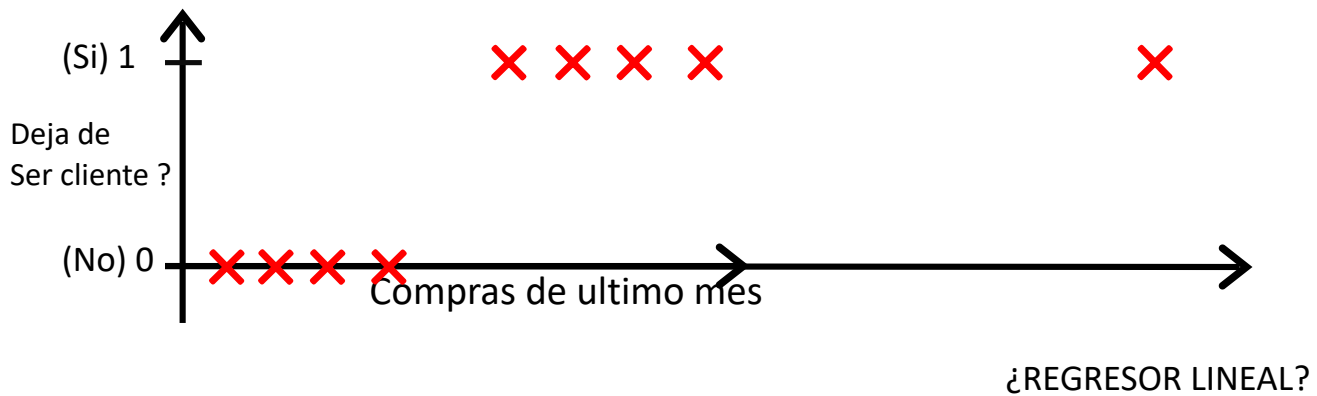
Tumor: ¿*Maligno* / *Benigno* ?

Cliente: *Confiable de crédito* ¿*Si* / *No*?

$$y \in \{0, 1\}$$

0: “Clase negativa” (e.g. tumor benigno)

1: “Clase positiva” (e.g. tumor maligno)



Threshold de clasificador $h_{\theta}(x)$ en 0.5:

Si $h_{\theta}(x) \geq 0.5$, predice “y = 1”

Si $h_{\theta}(x) < 0.5$, predice “y = 0”

Machine Learning Aplicado

3
...

Classificación: $y = 0$ o 1

$h_{\theta}(x)$ Puede ser > 1 o < 0

Regresión logística: $0 \leq h_{\theta}(x) \leq 1$

Machine Learning Aplicado

4
...

Regresión logística

Representación de hipotesis

Modelo de regresión logística


$$0 \leq h_{\theta}(x) \leq 1$$

$$h_{\theta}(x) = g(\theta^T x)$$

$\rightarrow g(z) = \frac{1}{1 + e^{-z}}$

$\theta^T x$

Función sigmoide
(función logística)



Interpretación de salida de hipotesis

$h_{\theta}(x)$ = probabilidad estimada de $y = 1$ dada entrada x

Ejemplo: Si $x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ \text{tumorSize} \end{bmatrix}$

$$h_{\theta}(x) = 0.7$$

Esto indica que hay 70% de chance de tumor maligno.

$$\underline{h_{\theta}(x)} = \underline{P(y=1|x;\theta)}$$

“probabilidad que $y = 1$, dado x , parametrizado por θ ”

$$P(y = 0|x; \theta) + P(y = 1|x; \theta) = 1$$

$$P(y = 0|x; \theta) = 1 - P(y = 1|x; \theta)$$

Machine Learning Aplicado

7
...

Una de las siguientes afirmaciones sobre la regresión logística (vista hasta el momento) es verdadera. Indique cuál es.

- ☐ La función de hipótesis es no lineal.
- ☐ La salida corresponde a un número real mayor a 0.
- ☐ Es adecuada para el problema de predicción de precio de limones para el día de mañana.
- ☐ Ninguna de las anteriores.


Regresión Logística

Bordes de decisión

Regresión logística

$$h_{\theta}(x) = g(\theta^T x)$$


$$g(z) = \frac{1}{1+e^{-z}}$$



Suponga predecir “ $y = 1$ ” if $h_{\theta}(x) \geq 0.5$

predecir “ $y = 0$ ” if $h_{\theta}(x) < 0.5$


Borde de decisión (lineal)



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

Predecir “ $y = 1$ ” si $-3 + x_1 + x_2 \geq 0$

Borde de decisión no-lineal



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

Predecir “ $y = 1$ ” if $-1 + x_1^2 + x_2^2 \geq 0$

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_1^2 x_2 + \theta_5 x_1^2 x_2^2 + \theta_6 x_1^3 x_2 + \dots)$$

Regresión logística

Función de costo

Training set: $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$

m ejemplos $x \in \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_n \end{bmatrix} \quad x_0 = 1, y \in \{0, 1\}$

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

¿Como escoger parametros θ ?


Función de costo de regresión logística

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$


Cost=0; si $y=1$, $h(x)=1$
Pero si $h(x) \rightarrow 0$ luego Cost \rightarrow inf.

Esto captura intuición que si $h(x)=0$ y dado que $y=1$, el costo se hace muy grande, lo que es coherente.

Si $y = 1$ (osea $\theta^T x \gg 0$):



Si $y = 0$ (osea $\theta^T x \ll 0$):



Machii

15

Regresión Logística

Función de costo simplificada
y descenso de gradiente

Función de costo de regresión logística

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$$

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

Nota: $y = 0$ o 1 ; no otro valor!.

Función de costo de regresión logística

$$\begin{aligned} J(\theta) &= \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) \\ &= -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right] \end{aligned}$$

Para ajustar parametro : θ

$$\min_{\theta} J(\theta)$$

Para hacer predicción dado nuevo data x :

Salida $h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$

Descenso de gradiente

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right]$$

Se requiere $\min_{\theta} J(\theta)$:

Repetir {

$$\theta_j := \theta_j - \alpha \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

$\frac{\partial}{\partial \theta_j} J(\theta)$
Operación para hallar mínimo!

(simultaneamente actualizar todo θ_j)

}

Algoritmo es casi idéntico a regresión lineal!

BONUS: SVM

Regresor logístico

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right] + \frac{1}{2} \sum_{i=1}^n \theta_j^2$$


Máquina de soporte vectorial (SVM)

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) \right] + \frac{1}{2} \sum_{i=1}^n \theta_j^2$$

$-\log(1 - \frac{1}{1+e^{-z}})$

$$\text{cost}_1(\theta^T x^{(i)}) = \max(0, 1 - \theta^T x)$$

$$\text{cost}_0(\theta^T x^{(i)}) = \max(0, 1 + \theta^T x)$$



$$y = 1$$

$$\theta^T x \gg 0$$

Tiene óptimo global!!: usando programación cuadrática.